

# Resumen microeconometria (Cameron & Trivedi)

---

Santiago Alonso-Díaz, PhD

Profesor Asistente  
Departamento de Economía  
Universidad Javeriana

# Modelos No Lineales

---


# Modelos No Lineales



Resuelva y escriba la expresión para:  
Un insecto que pesa 30 gramos al nacer aumenta su peso 20% al mes.  
Cuál es su peso luego de dos meses?

# Modelos No Lineales

Relaciones no lineales no son bien descritas por modelos lineales tradicionales pero si por GLMs.



Qué significa el intercepto? La pendiente? OLS captura el salto discreto en la figura de la izq.?

Muchas situaciones no lineales

**Table 5.5.** *Nonlinear Least Squares: Common Examples*

Model	Regression Function $g(\mathbf{x}, \beta)$
Exponential	$\exp(\beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3)$
Regressor raised to power	$\beta_1 x_1 + \beta_2 x_2^{\beta_3}$
Cobb–Douglas production	$\beta_1 x_1^{\beta_2} x_2^{\beta_3}$
CES production	$[\beta_1 x_1^{\beta_3} + \beta_2 x_2^{\beta_3}]^{1/\beta_3}$
Nonlinear restrictions	$\beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$ , where $\beta_3 = -\beta_2 \beta_1$

# Modelos No Lineales

El estimativo de los parámetros requiere cuidados adicionales. Por ejemplo, si buscamos minimizar cuadrados,

$$\sum_i (y_i - g(x_i, \beta))^2$$

$g()$  es una función lineal (e.g.  $x\beta$ ) o no lineal (e.g.  $e^{(x\beta)}$ ).

La derivada (chain rule) la igualamos a cero,

$$2 \times \sum_i \frac{\delta g_i}{\delta \beta} (y_i - g(x_i, \beta)) = 0$$

Si  $g$  es lineal i.e.  $x\beta$ , entonces  $\frac{\delta g_i}{\delta \beta} = x_i$

Qué significa que el producto (dot) de dos vectores sea cero?

Independencia! La función a optimizar (residuales al cuadrado) NO depende de  $x$

$$2 \times \sum_i \frac{\delta g_i}{\delta \beta} (y_i - g(x_i, \beta)) = 0$$

Si  $g()$  es no lineal  $\frac{\delta g_i}{\delta \beta}$  no es igual a  $x$  i.e. el residual depende de la derivada, no es independiente de  $x$ .

No hay forma analítica, se requieren métodos numéricos para estimar  $\hat{\beta}$   
(más de esto en siguientes diapositivas)

Ejemplo método numérico: Gradient Descent

([https://www.youtube.com/watch?v=A6FiCDoz8\\_4](https://www.youtube.com/watch?v=A6FiCDoz8_4))



Non\_linear\_regression.ipynb; Sección Visualización distribuciones y regresión

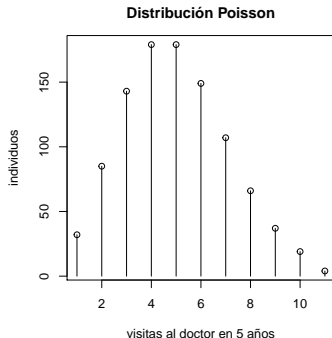


Ejemplo: Distribución Poisson

# Modelos No Lineales

La distribución Poisson sirve para modelar eventos discretos

Por ejemplo, visitas de individuos al doctor en 5 años, número de patentes por mes, o tasa de disparos de una neurona por segundo



La distribución Poisson tiene la siguiente masa,

$$f(y|\lambda) = \frac{e^{-\lambda} \lambda^y}{y!}$$

$y = 0, 1, 2, \dots$

$\lambda$ : parámetro libre

$E[y] = \lambda, \text{Var}[y] = \lambda$

Qué nos interesa en una regresión?  $E[y] = x\beta$

Qué es  $y$  en un proceso Poisson?

El parámetro  $\lambda$  varía acorde a los predictores y lo definimos,

$$\lambda = e^{x\beta}$$

La masa queda así,

$$f(y|x, \beta) = \frac{e^{-e^{x\beta}} (e^{x\beta})^y}{y!}$$

Dado que tenemos una función de probabilidad, maximizamos la verosimilitud de los datos para obtener los parámetros  $\beta$ . Si asumimos independencia,

$$\prod_i^n f(y_i|x_i, \beta)$$

Tomamos el logaritmo por conveniencia computacional (convertir a sumas), usamos el promedio ( $\frac{1}{N}$ ), e igualamos a cero la derivada de  $f(y_i|x_i, \beta)$  con respecto a  $\beta$

$$\frac{1}{N} \sum_{i=1}^N (y_i - e^{(x_i\beta)})x_i = 0$$

No hay solución explícita, por lo que el estimativo  $\hat{\beta}$  se obtiene por métodos numéricos

Interpretación de coeficientes



Efectos marginales ( $\frac{dy}{dx}$ ). Por ejemplo, cuanto aumenta el número de pacientes con otro seguro médico?. En un modelo lineal es el parámetro  $\beta$ ,

$$\frac{dy}{dx}(x\beta) = \beta$$

En un modelo no lineal el  $\beta$  ya no es el efecto marginal. Por ejemplo,

$$\frac{dy}{dx}(e^{x\beta}) = e^{x\beta} \beta$$

El efecto marginal también depende del predictor  $x$

Como el efecto marginal depende del predictor  $x$ , estas son posibles soluciones

**Table 5.2.** *Marginal Effect: Three Different Estimates*

Formula	Description
$N^{-1} \sum_i \partial E[y_i   \mathbf{x}_i] / \partial \mathbf{x}_i$	Average response of all individuals
$\partial E[y   \mathbf{x}] / \partial \mathbf{x}  _{\bar{\mathbf{x}}}$	Response of the average individual
$\partial E[y   \mathbf{x}] / \partial \mathbf{x}  _{\mathbf{x}^*}$	Response of a representative individual with $\mathbf{x} = \mathbf{x}^*$

Non\_linear\_regression.ipynb; Sección Efectos marginales no lineales  
dependen del valor del predictor



Single index models. Si el regresor  $x_j$  (e.g.  $j = 1$ : ingreso,  $j = 2$ : *genes*, etc) y los parámetros  $\beta$  entran a la función no lineal  $g()$  directamente i.e.  $g(x\beta)$  por chain rule los efectos marginales son

$$\frac{dy}{dx_j} g(x\beta) = g'(x\beta) \beta_j$$

Si hacemos una comparación relativa del efecto marginal de dos regresores  $j$  &  $k$  (e.g. ingreso y genes),

$$\frac{g'(x\beta)\beta_j}{g'(x\beta)\beta_k} = \frac{\beta_j}{\beta_k}$$

Así, por ejemplo, si  $\beta_j$  es el doble de  $\beta_k$ , una unidad de cambio del regresor  $j$  (e.g. ingreso) tiene el doble de efecto que una unidad del regresor  $k$  (e.g. genes)

En suma, hay que tener cuidado con la interpretación de los coeficientes en un modelo no lineal.

Pueden indicar fuerza de relación con la respuesta  $y$ , pero dependen del valor que tome el regresor  $x$ .

Estimación de coeficientes (MLE & NLS)

En MLE (maximum likelihood estimate) se maximiza la verosimilitud o likelihood de la data  $f(y, X|\theta)$  dado un vector de parámetros  $\theta$

OJO: el likelihood function  $L_N(\theta|y, X)$  que se usa en MLE es una función de los parámetros.



NO confundir  $f(y, X|\theta)$  (likelihood) con la función  $L_N(\theta|y, X)$ . Esta última también le dicen likelihood pero es la función a optimizar.

TAMPOCO confundir  $L_N(\theta|y, X)$  con posterior bayesiana  $f(\theta|y, X)$  que está ponderada por priors. Las funciones  $f$  son probabilidades condicionales.

Non\_linear\_regression.ipynb; Sección Diferentes sentidos de likelihood



Para usar MLE necesitamos una densidad i.e. tenemos que parametrizar las densidades en función de los regresores  $\mathbf{x}$  & parámetros  $\beta$

**Table 5.3.** *Maximum Likelihood: Commonly Used Densities*

Model	Range of $y$	Density $f(y)$	Common Parameterization
Normal	$(-\infty, \infty)$	$[2\pi\sigma^2]^{-1/2}e^{-(y-\mu)^2/2\sigma^2}$	$\mu = \mathbf{x}'\beta, \sigma^2 = \sigma^2$
Bernoulli	0 or 1	$p^y(1-p)^{1-y}$	Logit $p = e^{\mathbf{x}'\beta}/(1 + e^{\mathbf{x}'\beta})$
Exponential	$(0, \infty)$	$\lambda e^{-\lambda y}$	$\lambda = e^{\mathbf{x}'\beta}$ or $1/\lambda = e^{\mathbf{x}'\beta}$
Poisson	0, 1, 2, ...	$e^{-\lambda}\lambda^y/y!$	$\lambda = e^{\mathbf{x}'\beta}$

Non\_linear\_regression.ipynb; Sección MLE



## Generalized Linear Models (GLM)

Fuente: [Gelman and Hill, 2006]

Qué es un GLM?

- ▶ Predictores  $x\beta$
- ▶ Una link function  $g()$  para la data y e.g. binomial
- ▶  $g()$  produce un vector de data transformada  $\hat{y} = g^{-1}(x\beta)$  que se usa para parametrizar la distribución de la data  $p(y|\hat{y})$
- ▶ Una distribución de la data  $p(y|\hat{y})$
- ▶ Parámetros adicionales (e.g. para la link function o la distribución de la data)

Ejemplo: regresión lineal


- ▶ Predictores:  $x\beta$
- ▶ Link function: identidad  $g(u) = u$
- ▶ Data transformada:  $\hat{y} = g^{-1}(x\beta) = x\beta$
- ▶ Distribución data:  $y \sim N(\hat{y}, \sigma)$ ;  $\sigma$  se estima con la data

Ejemplo: regresión logística

- ▶ Predictores:  $x\beta$
- ▶ Link function:  $g(u) = \log\left(\frac{u}{1-u}\right)$
- ▶ Data transformada:  $\hat{y} = g^{-1}(x\beta) = \frac{1}{1+e^{-x\beta}}$
- ▶ Distribución data:  $y \sim \text{binomial}(n, p = \hat{y})$ ;  $n$  es el numero de observaciones



## Ejemplo práctico: regresión logística



La regresión logística se usa para modelar resultados binarios.

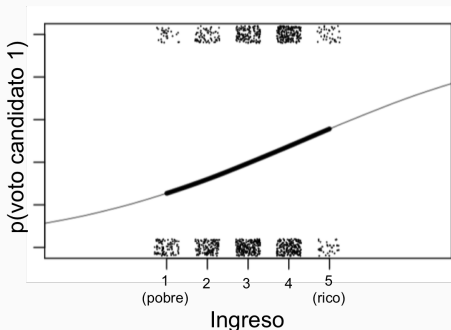
Por ejemplo, el voto por dos candidatos en función del ingreso

# Modelos No Lineales

Esta data es de una elección entre dos candidatos. La regresión logística dio  $\beta_{intercepto} = -1.4$ ,  $\beta_{ingreso} = 0.33$ .

Es decir,  $p(\text{voto a candidato 1}) = \text{logit}^{-1}(-1,4 + 0,33\text{ingreso}) = \frac{1}{1+e^{-(-1,4+0,33\text{ingreso})}}$

Qué significan los  $\beta$ s? Con cuidado! no es lineal y la escala ya no es la de la data, todo esta en  $[0,1]$ .




# Modelos No Lineales

Tip 1: evaluar el modelo en el promedio o media de la data.

Para interpretar  $\beta_{intercepto} = -1.4$ :

Ingreso es categórico y la categoría media es 3. Así,

$p(\text{voto a candidato 1}) = \frac{1}{1+e^{-(-1,4+0,33 \times 3)}} = 0,4$ . Es decir, en el ingreso medio la probabilidad de votar por candidato 1 es 0.4



Tip 1: evaluar el modelo en el promedio o media de la data.

Para interpretar  $\beta_{\text{ingreso}} = 0.33$ :

Evaluar un cambio de ingreso e.g. ingreso medio - ingreso anterior

$\frac{1}{1+e^{-( -1,4+0,33 \times 3)}} - \frac{1}{1+e^{-( -1,4+0,33 \times 2)}} = 0,08$ . Es decir, un aumento de categoría de ingreso aumenta la probabilidad de votar por candidato 1 en 8%

Tip 2: dividir los coeficientes por 4 (excepto el intercepto).

Suena raro pero tiene una razón:  $\frac{\beta}{4}$  es la máxima diferencia de cambio de probabilidad en la función logistic correspondiente a un cambio en el predictor  $x$  [Gelman and Hill, 2006].

Por ejemplo,  $\frac{\beta_{\text{ingreso}}}{4} = \frac{0,33}{4} = 0,08$ . Este es el valor de la anterior diapositiva i.e. encontramos el máximo cambio de probabilidad de votar por unidad de ingreso.

OJO: esto es para evaluar cambios máximos y se debe interpretar como tal.

Tip 3: odds ratios i.e. exponenciar los coeficientes.

$e^{\beta_{\text{ingreso}}} = e^{0,33} = 1,39$ . Es decir, un cambio en el ingreso aumenta el ratio de posibilidades de votar por candidato 1 en 1.39 (todo lo demás constante).

Qué quiere decir esto? Gelman y colegas afirman, con razón, que los odds ratios son poco intuitivos y prefieren usar cambios en probabilidad como las anteriores diapositivas.

Qué hacer si hay más regresores? Por ejemplo

$$p(\text{voto a candidato 1}) = \frac{1}{1 + e^{-(-1,4 + 0,33\text{ingreso} + 2,12\text{educacion})}}$$

De nuevo, se puede evaluar el modelo en una referencia e.g. promedio de los otros regresores y evaluar el marginal del regresor de interés

## Ejemplo práctico: Poisson



La distribución Poisson se usa para modelar conteos.

Por ejemplo, número de accidentes en una intersección en función de velocidad y presencia o no de semáforo



Si  $y_i$  es el número de accidentes en la intersección  $i$ ,

$$y_i \sim \text{Poisson}(\theta_i)$$

El parámetro  $\theta_i$  debe ser positivo, así que


$$\theta_i = e^{x\beta}$$

Para agregar un baseline o exposure en los conteos (e.g. para controlar por número de vehículos que pasan por la intersección) añadimos un parámetro,

$$y_i \sim \text{Poisson}(\text{exposure}_i \times \theta_i)$$

El  $\log(\text{exposure})$  se llama offset

# Modelos No Lineales



Suponga que luego de ajustar el modelo encuentra que,

$$y_i \sim \text{Poisson}(e^{2,8+0,012\text{AvgVel}_i-0,2\text{TfcLight}_i})$$

Qué significan los  $\beta$ s de los regresores?

$$y_i \sim \text{Poisson}(e^{2,8+0,012\text{AvgVel}_i-0,2\text{TfcLight}_i})$$

Para AvgVel, el coeficiente 0.012 es la diferencia esperada en accidentes por cada km/h adicional.


por qué?  $E[y] = \theta$  para una Poisson, por eso podemos interpretar  $e^{0,012} = 1,012$  como un incremento de 1.2% en accidentes por cada km/h adicional.

-0.2 para traffic light (0: no hay semáforo, 1: si)? Es similar, use el signo y la magnitud  $e^{-0,2}$

Paréntesis conceptual: cuando Binomial o Poisson?

- ▶ Binomial se usa cuando la data  $y_i$  son eventos sobre un total  $n$
- ▶ Poisson se usa cuando la data  $y_i$  son eventos sin un límite  $n$  superior

Non\_linear\_regression.ipynb; Sección Poisson police stops



En este punto debe ser claro que regresión no-lineal difiere de la lineal (estimación e interpretación). Reforcemos con el siguiente ejemplo,

$$y = \lambda e^{-\lambda}$$

$\lambda = e^{(\beta_1 + \beta_2 x)}$ , y asumamos que  $\beta_1 = 2$  y  $\beta_2 = -1$

# Modelos No Lineales

Todos los métodos no lineales aciertan los  $\beta$ s pero difieren en OLS Por qué? Identificación

Imagine que y es salud, x ingreso. Signos en OLS diferentes conclusiones diferentes? NO!!


**Table 5.7.** *Exponential Example: Least-Squares and ML Estimates<sup>a</sup>*

Variable	Estimator				
	OLS	ML	NLS	WNLS	FGNLS
Constant	-0.0093 (0.0161) [0.0172]	1.9829 (0.0141) [0.0144]	1.8876 (0.0307) [0.1421] {0.2110}	1.9906 (0.0225) [0.0359]	1.9840 (0.0148) [0.0146]
x	0.6198 (0.0113) [0.0254]	-0.9896 (0.0099) [0.0099]	-0.9575 (0.0097) [0.0612] {0.0880}	-0.9961 (0.0098) [0.0224]	-0.9907 (0.0100) [0.0101]
lnL	-	-208.71	-232.98	-208.93	-208.72
R <sup>2</sup>	0.2326	0.3906	0.3913	0.3902	0.3906



# Modelos No Lineales

Los (signos)  $\beta$  en regresiones no lineales NO se pueden interpretar como efectos marginales i.e.  $y$  es monótonica en  $x$  tanto para OLS y NLS



Calcule la derivada  $dy/dx$  de  $y = e^{-(\beta_1 + \beta_2 x)}$  (chain rule). Es positivo en todo el dominio?

Caso probit: cyberbullying CAUSA aumento de tasas de suicidio?



[Nikolaou, 2017]

Algunos datos de Cyberbullying en Colombia. Lo sufren más los hombres y en colegios públicos

**Tabla 3** Implicación en *bullying* (%)

	Sexo		Edad			Estrato			Colegio		Curso						
Implicación	Masc. n = 878	Femen. n = 999	≤ 13 n = 709	14-15 n = 663	≥ 16 n = 506	Bajo n = 400	Medio-bajo n = 509	Medio-alto n = 608	Alto n = 339	Público n = 1253	Privado n = 629	6.º n = 323	7.º n = 348	8.º n = 379	9.º n = 301	10.º n = 237	11.º n = 293
Victimización	53.6***	46.4	42.9	33.1	24	20.8	25.5	35.2**	18.5	62.6***	37.4	19.3	21.5	18.4	14.7	10.9	15.2
Agresión	67.1***	32.9	34.1	34.1	31.8	21.4	25	32.2**	21.4	62.4***	37.6	7.1	20	23.5***	15.3	15.3	18.8
Agresión- victimización	61.2***	38.8	32.4	42.1*	25.5	17.7	22.4	33.5**	26.4	53.5***	46.5	10.4	15.8	24.6**	19.2	15	15
* $p < .05$ .																	
** $p < .01$ .																	
*** $p < .001$ .																	

[Herrera-Lopez et al., 2017]

La conexión con suicidio es anecdótica o correlacional. Algunos casos mediáticos en EE.UU.



Ryan Halligan  
1989-2003

Niña fingió que lo quería  
para reírse de sus chats



Megan Meier  
1992-2006

Crearon una cuenta  
falsa para enamorarla

Antecedentes/literatura previa. Problemática (económica no moral).

- ▶ Cyberbullying puede reducir el capital de salud individual (intentos de suicidio fallidos)
- ▶ También el capital de salud de la economía (intentos de suicidio fatales)


[Nikolaou, 2017]

Antecedentes/literatura previa. Relación con economía.

- ▶ Tiene una racionalidad si el valor futuro de mantenerse vivo es negativo
- ▶ Mayor probabilidad de suicidio si el flujo de ingresos futuros es bajo o incierto
- ▶ Hay más suicidios en recesiones económicas pero en términos relativos i.e. si todos están desempleados no hay más suicidios.

[Nikolaou, 2017]

Antecedentes/literatura previa. Relación con edad (gráfica ilustrativa, no datos reales)



[Nikolaou, 2017]

Antecedentes/literatura previa. Relación con género

- ▶ Mujeres tienen más ideaciones de suicidio no fatal
- ▶ Los hombres completan más intentos de suicidio.
- ▶ Mujeres escogen métodos menos violentos (pastillas) que los hombres (pistolas u colgarse).

[Nikolaou, 2017]



Antecedentes/literatura previa. Relación con variables socioeconómicas

- ▶ Raza: blancos caucásicos se suicidan más
- ▶ Salud física (e.g. obesidad) y mental (depresión, anorexia) lleva a más suicidios.
- ▶ La correlación entre nivel de ingresos y tasa de suicidios es baja.

[Nikolaou, 2017]

Antecedentes/literatura previa. Relación con juventud y cyberbullying

- ▶ Hay muchos estudios correlacionales que conectan suicidio y cyberbullying.
- ▶ Estudios causales previos muestran que bullying perjudica resultados educativos y laborales.
- ▶ Ninguno conecta causalmente cyberbullying con suicidio

[Nikolaou, 2017]

Modelo cognitivo. El objetivo de todo joven es maximizar  $Z$ .

$$Z(a, Y, s) = \int_a^{\omega} e^{-r(m-a)} U[C(m, Y(s(\cdot))) - K(m, s(\cdot))] P(m, s(\cdot)) dm$$

$U()$ ,  $C()$ , &  $K()$  son utilidad, consumo, y costos de mantenerse vivo para cada edad  $m$ , respectivamente.

$P()$  probabilidad de sobrevivir hasta la edad  $m$  condicional a que se vive hasta  $a$ .

$Y$  nivel de ingreso disponible para consumir.

$\omega$  expectativa de vida máxima.

$r$  tasa de descuento

$s()$  función de comportamiento suicida.

[Nikolaou, 2017]

Tres aspectos relevantes de la formula: 1) ideación suicida ( $s(\cdot)$ ) es input de la función  $P(\cdot)$ , probabilidad de sobrevivir. Es decir, en el modelo tener ideas suicidas reduce la probabilidad de seguir vivo.

$$Z(a, Y, s) = \int_a^{\omega} e^{-r(m-a)} U[C(m, Y(s(\cdot))) - K(m, s(\cdot))] P(m, s(\cdot)) dm$$

[Nikolaou, 2017]

Tres aspectos relevantes de la formula: 2)  $C$ , consumo, y  $K$ , mantenerse con vida, también dependen de ideaciones suicidas ( $s(\cdot)$ ). Por ejemplo, si una ideación suicida se ejecuta fallidamente, eso puede provocar vergüenza y disminuir consumo (e.g. no salir con amigos después del intento).

$$Z(a, Y, s) = \int_a^{\omega} e^{-r(m-a)} U[C(m, Y(s(\cdot))) - K(m, s(\cdot))] P(m, s(\cdot)) dm$$

[Nikolaou, 2017]

Tres aspectos relevantes de la formula: 3) la función  $s()$ , ideación suicida, depende de características individuales  $X$ , variables no observadas  $u$ , y la calidad del ambiente social  $Q$  del estudiante. La derivada parcial con respecto a  $Q$  es negativa i.e mejor ambiente  $Q$  menor ideación suicida.

$$s = s(X, Q; u), \frac{ds}{dQ} < 0$$

[Nikolaou, 2017]

Por otro lado,  $\frac{dQ}{d\text{Cyberbullying}} < 0$  i.e. cyberbullying reduce calidad de ambiente social Q.

También se asume en el modelo que  $\frac{d\text{Cyberbullying}}{d\text{Law}} < 0$  i.e. leyes pueden reducir cyberbullying.

[Nikolaou, 2017]

La decisión final de suicidarse o no es una comparación entre el valor esperado  $Z$  dado que hay suicidio ( $s()=1$ ) o no ( $s()=0$ ).

$$Z(a, Y|s(\cdot) = 1) > Z(a, Y|s(\cdot) = 0)$$

[Nikolaou, 2017]



Ahora sí las regresiones. Data=Youth Risk Behavioral Survey (1991-2015)

El instrumento propuesto es leyes en contra de cyberbullying.

Discusión Es un buen instrumento bajo el modelo propuesto? Las leyes afectan directamente el comportamiento suicida?

Formula de regresión probit. Segunda etapa:

$$S_{it} = \beta_0 + \beta_1 C_{it} + \beta_2 X_{it} + \beta_3 Z_{st} + \beta_4 H_{st} + \mu_s + \gamma_t + u_{it}$$

Primera etapa (instrumentos):

$$C_{it} = \alpha_0 + \alpha_1 CBL_{st} + \alpha_2 X_{it} + \alpha_3 Z_{st} + \alpha_4 H_{st} + \mu_s + \gamma_t + \epsilon_{it}$$

$S_{it}$ : comportamiento suicida individuo  $i$  en periodo  $t$ ;  $C_{it}$ : cyberbullying;  $X_{it}$ : características socioeconómicas;  $Z_{st}$ : características económicas del estado  $s$  en periodo  $t$ ;  $H_{st}$  controles de métricas de salud;  $\mu_s$ : efectos fijos de estado;  $\gamma_t$ : shocks en tasa de suicidio;  $\mu_{it}$ : shocks en preferencias de suicidio;  $CBL_{st}$ : leyes combatiendo cyberbullying en estado  $s$  en periodo  $t$ . [Nikolaou, 2017]

Por qué nos interesa más  $\beta_1$  que  $\alpha_1$ ?

$$S_{it} = \beta_0 + \beta_1 C_{it} + \beta_2 X_{it} + \beta_3 Z_{st} + \beta_4 H_{st} + \mu_s + \gamma_t + u_{it}$$

$$C_{it} = \alpha_0 + \alpha_1 CBL_{st} + \alpha_2 X_{it} + \alpha_3 Z_{st} + \alpha_4 H_{st} + \mu_s + \gamma_t + \epsilon_{it}$$

[Nikolaou, 2017]

Por qué instrumentalizar la variable cyberbullying  $C_{it}$ ? Es endógena?  
Pertener a la población cyberbullied es aleatorio? O los cyberbullied tienen características especiales?

$$S_{it} = \beta_0 + \beta_1 C_{it} + \beta_2 X_{it} + \beta_3 Z_{st} + \beta_4 H_{st} + \mu_s + \gamma_t + u_{it}$$

$$C_{it} = \alpha_0 + \alpha_1 CBL_{st} + \alpha_2 X_{it} + \alpha_3 Z_{st} + \alpha_4 H_{st} + \mu_s + \gamma_t + \epsilon_{it}$$

[Nikolaou, 2017]

# Modelos No Lineales

Efectos marginales (2nd stage): Cyberbullying aumenta 11% planes, 8.7% intentos, y 4.8% heridas por suicidio.

Marginal effects of c

	Second stage		
	Suicide plans [3]	Attempt suicide [4]	Suicide injury [5]
Cyberbullying	0.117*** (0.008)	0.087*** (0.030)	0.048*** (0.009)
Male	-0.057*** (0.004)	-0.008** (0.003)	0.001 (0.001)
Black	-0.021*** (0.003)	0.018*** (0.005)	0.012*** (0.002)
Hispanic	0.003 (0.004)	0.021*** (0.003)	0.010*** (0.002)
Other race	0.018*** (0.002)	0.020*** (0.002)	0.009*** (0.001)
Age 15	0.005*** (0.001)	0.005*** (0.002)	0.004*** (0.001)
Age 16	0.013*** (0.002)	0.014*** (0.002)	0.008*** (0.001)
Age 17	0.016*** (0.002)	0.018*** (0.003)	0.011*** (0.002)
Age 18 plus	0.013*** (0.003)	0.024*** (0.004)	0.015*** (0.002)
Grade 10	-0.008*** (0.002)	-0.008*** (0.001)	-0.004*** (0.001)
Grade 11	-0.021*** (0.002)	-0.019*** (0.002)	-0.008*** (0.001)
Grade 12	-0.029*** (0.003)	-0.027*** (0.003)	-0.011*** (0.002)
Underweight	0.011*** (0.004)	0.003 (0.002)	0.000 (0.001)
Overweight	0.012***	0.007***	0.003***

# Modelos No Lineales

Efectos marginales (1st stage): La leyes antibullying y anticyberbullying disminuyen cyberbullying pero no pensamientos suicidas buen instrumento?

Marginal effects of cyberbullying on suicidal behaviors, bivariate probit estimates.

	First stage	
	Cyberbullying [1]	Suicidal thoughts [2]
Obese	0.010** (0.003)	0.033** (0.003)
Unsafe at school	0.174** (0.006)	0.146** (0.005)
Unemployment rate	0.001 (0.002)	-0.008 (0.006)
Beer tax	0.002 (0.006)	-0.005 (0.012)
Cigarettes tax	-0.000 (0.000)	0.000 (0.000)
Population	-0.000 (0.001)	0.000 (0.001)
Mental health expenses	-0.000 (0.000)	0.000 (0.000)
Health consumption	0.000 (0.000)	0.000 (0.000)
Suicide prevention law	-0.000 (0.004)	0.019** (0.009)
Mental health law	0.007* (0.004)	0.012* (0.007)
Anti-bullying law	-0.015** (0.006)	-0.005 (0.009)
Income (per capita)	-0.000 (0.000)	-0.000 (0.000)
Cyberbullying law	0.010**	

Estamos seguros que encontramos un efecto causal via el instrumento?  
Comparamos niños con las mismas características?

Paréntesis pedagógico: Propensity Score Matching

Objetivo: construir grupos de control con la data que se tiene (que no siempre viene de experimentos propiamente diseñados)



# Modelos No Lineales

Opción 1: Exact matching.

Ideal pero problema combinatorio que explota rápidamente con número de características a match.

**Figure 8.1 Exact Matching on Four Characteristics**

Treated units			
Age	Gender	Months unemployed	Secondary diploma
19	1	3	0
35	1	12	1
41	0	17	1
23	1	6	0
55	0	21	1
27	0	4	1
24	1	8	1
46	0	3	0
33	0	12	1
40	1	2	0


Untreated units			
Age	Gender	Months unemployed	Secondary diploma
24	1	8	1
38	0	1	0
58	1	7	1
21	0	2	1
34	1	20	0
41	0	17	1
46	0	9	0
41	0	11	1
19	1	3	0
27	0	4	0

# Modelos No Lineales

Opción 2: Propensity score matching.

A cada unidad/individuo le asignamos una probabilidad de ser tratado basado en las características. Es una medida continua entre 0-1.

**Figure 8.2 Propensity Score Matching and Common Support**



Supuestos para hacer un buen matching

- ▶ Independencia condicional

Recordemos independencia condicional

**Correlación -**

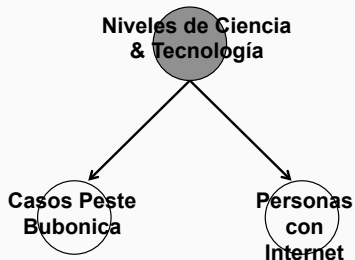
**Casos Peste  
Bubonica**



**Personas  
con  
Internet**




Recordemos independencia condicional



# Modelos No Lineales

En matching, necesitamos que el tratamiento (e.g. ayuda monetaria o no) sea independiente de los resultados (e.g. vocabulario) dadas una características (e.g. nivel de ingreso familiar).

Por ejemplo, un programa de becas que ayude monetariamente no vaya a priori a buenos estudiantes si el objetivo es ver mejora en el vocabulario.



Supuestos para hacer un buen matching

- ▶ Independencia condicional
- ▶ Soporte común


# Modelos No Lineales

Soporte común:

$0 < P[\text{tratamiento} = 1|x] < 1$  i.e. la probabilidad de ser tratado, dada unas características  $x$ , es mayor a cero.

Por qué necesitamos esto? Qué pasa si las dos curvas de la gráfica no se intersectan?

Figure 8.2 Propensity Score Matching and Common Support





Cómo calcular propensity matching score? i.e.  
 $p(\text{tratamiento}|\text{características})$

Una forma es con una regresión logística i.e. *tratamiento* ~ *características*.

Todos los que tengan valor logit suficientemente cercano agruparlos.

Non\_linear\_regression.ipynb; Sección Propensity score matching



Volvamos a cyberbullying ... en las siguientes diapositivas con la data PSM (propensity score match)

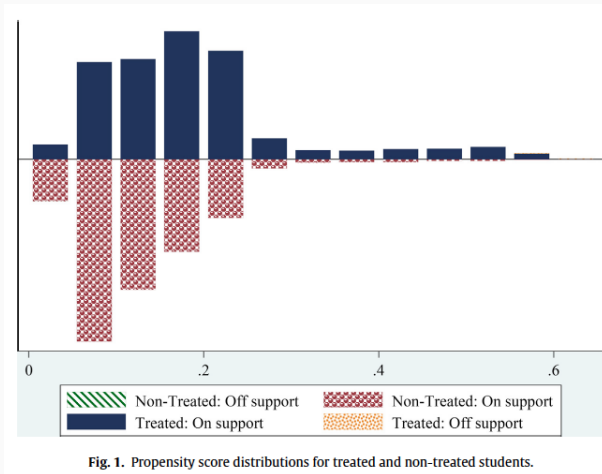
Marginal effects of c

	Second stage		
	Suicide plans [3]	Attempt suicide [4]	Suicide injury [5]
Cyberbullying	0.117*** (0.008)	0.087*** (0.030)	0.048*** (0.009)
Male	-0.057*** (0.004)	-0.008** (0.003)	0.001 (0.001)
Black	-0.021*** (0.003)	0.018*** (0.005)	0.012*** (0.002)
Hispanic	0.003 (0.004)	0.021*** (0.003)	0.010*** (0.002)
Other race	0.018*** (0.002)	0.020*** (0.002)	0.009*** (0.001)
Age 15	0.005*** (0.001)	0.005*** (0.002)	0.004*** (0.001)
Age 16	0.013*** (0.002)	0.014*** (0.002)	0.008*** (0.001)
Age 17	0.016*** (0.002)	0.018*** (0.003)	0.011*** (0.002)
Age 18 plus	0.013*** (0.003)	0.024*** (0.004)	0.015*** (0.002)
Grade 10	-0.008*** (0.002)	-0.008*** (0.001)	-0.004*** (0.001)
Grade 11	-0.021*** (0.002)	-0.019*** (0.002)	-0.008*** (0.001)
Grade 12	-0.029*** (0.003)	-0.027*** (0.003)	-0.011*** (0.002)
Underweight	0.011*** (0.004)	0.003 (0.002)	0.000 (0.001)
Overweight	0.012***	0.007***	0.003***

# Modelos No Lineales

## Distribución PSM

Por qué se cumple el supuesto de common support?



## Limites de propensity score matching

- ▶ Se requiere una base de datos grande que cumpla el supuesto de common support
- ▶ El match se hace solo con observables i.e. asume que los no observables en las unidades control y tratamiento son similares

El resultado sobre cyberbullying y tendencias suicidas se mantienen con distintos **algoritmos PSM**

**Table 3**

Propensity score estimates for the effects of cyberbullying on suicidal behaviors.

	Suicidal thoughts	Suicide plans	Attempt suicide	Suicide injury
Nearest neighbor	0.149 <sup>***</sup> (0.004)	0.118 <sup>***</sup> (0.004)	0.071 <sup>***</sup> (0.004)	0.023 <sup>***</sup> (0.003)
Radius	0.179 <sup>***</sup> (0.007)	0.139 <sup>***</sup> (0.007)	0.091 <sup>***</sup> (0.005)	0.032 <sup>***</sup> (0.003)
Kernel	0.143 <sup>***</sup> (0.006)	0.110 <sup>***</sup> (0.004)	0.064 <sup>***</sup> (0.003)	0.024 <sup>***</sup> (0.002)
Mean standardized bias (MSB) <sup>a</sup>	0.7	0.7	0.7	0.7
Pseudo-R <sup>2a,b</sup>	0.001	0.001	0.001	0.001

[Nikolaou, 2017]

# Modelos No Lineales

Es cyberbullying law un buen instrumento para cyberbullying?

Endogeneidad: Se relaciona la ley con cyberbullying? (panel A incluye # de estados cercanos con leyes; para controlar spillover effects)

Falsificación; Se relaciona la ley con otras variables/unobserved? (panel B)

**Table 4**

Additional tests for the validity of cyberbullying laws as instruments for cyberbullying in the bivariate probit models.

*Panel A—policy endogeneity<sup>a</sup>*

	Cyberbullying law	Cyberbullying
Number of neighboring states	0.519*** (0.115)	—
Cyberbullying law	—	−0.010* (0.004)

*Panel B—falsification tests<sup>b</sup>*

	Violent crime	Property crime	Property crime
Cyberbullying law	−0.031 (0.182)	−0.023 (0.090)	−0.002 (0.008)

Modelos multinomiales





Non\_linear\_regression.ipynb; Sección Multinomial M and M



Otros ejemplos:

- ▶ Transporte (bus, carro, bicicleta, taxi, caminar)
- ▶ Seguro médico (EPS, EPS-Prepagada, Ninguno)
- ▶ Estatus laboral (Tiempo completo, Medio tiempo, Desempleado)
- ▶ Ocupación (Ingeniero, Músico, Médico, Economista, Psicólogo, Abogado)

Multinomial logit (con categorías que NO se pueden ordenar)

# Modelos No Lineales

Cuál color de m&m escogen?



Cuál consola escogen?



Additive random-utility model:

Con categorías multinomiales que no tienen un orden claro, se asume que los individuos escogen la que les represente mayor utilidad

La utilidad de la alternativa  $j$  para el individuo  $i$  es

$$U_{ij} = Valor_{ij} + \epsilon_{ij}$$

Valor depende de  $x$ : aspectos específicos de la alternativa (e.g. precio), &  
 $z$ : aspectos independientes de la alternativa (e.g. genero del individuo)

$$Valor_{ij} = x_{ij}\beta + z_i\gamma_j$$

La alternativa escogida ( $y$ ) es la de mayor utilidad

$$P(y = j) = P(U_{ij} \geq U_{ik}) \text{ para todo } k \neq j$$

Una forma de asignar utilidades en función de regresores  $j$  es con la función softmax,

$$p_{ij} = \frac{e^{x_i \beta_j}}{\sum_{l=1}^m e^{x_i \beta_l}}$$

Los  $\beta$ s incluyen el intercepto: los otros coeficientes son relativos a ese valor como en un regresión lineal clásica

Se asume que el individuo  $i$  escoge la opción  $j$  con probabilidad dada por la formula i.e  $\sum_{j=1}^m p_{ij} = 1$

Non\_linear\_regression.ipynb; Sección Regresión Multinomial  
(non-ordinal logistic regression)





Multinomial logit (con categorías que se pueden ordenar)

# Modelos No Lineales

Las K categorías se pueden modelar en función de una variable continua  $X\beta$ . Los puntos de cortes  $c$  son estrictamente crecientes i.e.

$$0 = c_1 < c_2 < \dots < c_k$$

$$P(y > 1) = \text{logit}^{-1}(X\beta - c_1)$$

$$P(y > 2) = \text{logit}^{-1}(X\beta - c_2)$$

$$P(y > 3) = \text{logit}^{-1}(X\beta - c_3)$$

...


$$P(y > K - 1) = \text{logit}^{-1}(X\beta - c_{k-1})$$

La resta de dos valores consecutivos nos da  $P(y=k)$ ,

$$P(y = k) = P(y > k - 1) - P(y > k)$$

$$P(y = k) = \text{logit}^{-1}(X\beta - c_{k-1}) - \text{logit}^{-1}(X\beta - c_k)$$

Visualización de  $P(y = k)$  i.e. la porción naranja que queda descubierta



Otra forma de escribirlo con una variable latente  $z$ :

$$f(x) = \begin{cases} 1 & \text{if } z_i < 0 \\ 2 & \text{if } z_i \in (0, c_2) \\ 3 & \text{if } z_i \in (c_2, c_3) \\ \dots & \\ K-1 & \text{if } z_i \in (c_{K-2}, c_{K-1}) \\ K & \text{if } z_i > c_{K-1} \end{cases}$$

$$z_i = X_i\beta + \epsilon_i$$

Con distribución logística para el error  $\epsilon_i$  i.e.  $\frac{1}{1+e^{-\epsilon_i}}$ . Hay que estimar  $\beta$  y los cortes  $c$  (con MLE).

Ejemplo (experimento):

6 jugadores van a votar sobre dos temas durante 30 rondas

Cada jugador tiene tres votos y cada ronda gana el tema con más votos. Primero se vota por tema 1 y los votos restantes van automáticamente al tema 2.

Antes del voto por el tema 1, los experimentadores le dicen a los sujetos que tanto ganan si pasa el tema en esa ronda (entre 1-100).

El número de votos (categorías)  $y_i$  se pueden modelar así. El  $\sigma$  se puede pensar como fuzzyness de las categorías &  $z$  como utilidad esperada.

$$y_i = \begin{cases} 1 & \text{if } z_i < c_{1|2} \\ 2 & \text{if } z_i \in (c_{1|2}, c_{2|3}) \\ 3 & \text{if } z_i > c_{2|3} \end{cases}$$

$$z_i \sim \text{logistic}(\text{ganancia}_i, \sigma^2)$$



Gelman, A. and Hill, J. (2006).

***Data analysis using regression and multilevel/hierarchical models.***

Cambridge university press.



Gertler, P. J., Martinez, S., Premand, P., Rawlings, L. B., and Vermeersch, C. M. (2016).

***Impact evaluation in practice.***

The World Bank.



Herrera-Lopez, M., Romera, E., and Ortega-Ruiz, R. (2017).

**Bullying y cyberbullying en colombia; coocurrencia en adolescentes escolarizado.**

*Revista Latinoamericana de Psicología*, 49:163–172.



Nikolaou, D. (2017).

**Does cyberbullying impact youth suicidal behaviors?**

*Journal of health economics*, 56:30–46.